

Primo Esonero

Alessandro Angeletti
2063329

Gennaro Bernardo
2103184

David Gancino Oyos
2118949

1 Obiettivo del progetto

Realizzazione di un parser per pagine web. Dato un indirizzo, scarica html text, lo elabora estrapolandone il titolo e il testo ripulito. Valuta l'efficacia del parsing confrontando il testo scaricato con il testo corretto caricato precedentemente.

2 Organizzazione del codice

Il codice è formato principalmente in due parti: **frontend** e **backend**.

Il **frontend** si occupa di effettuare richieste al backend ed è in ascolto sulla porta 8004; inoltre, tramite *jinja2*, mette su una piccola interfaccia grafica, oltre a quella fornita da /docs, per poter comunicare con il backend ed effettuare tutte le operazioni sviluppate. Nella cartella del frontend troviamo il file `frontend.py`, dove sono state inserite tutte le operazioni necessarie al progetto tramite *FastAPI*, e la cartella `templates` che contiene il file HTML necessario a *jinja2* per poter visualizzare l'interfaccia grafica.

Il **backend**, in ascolto sulla porta 8003, si occupa di elaborare le richieste ricevute, ritornando ciò che l'utente si aspetta. All'interno della cartella del backend c'è il file `server.py` del backend stesso, un file `valuation.py` in cui sono state inserite due funzioni per l'evaluation (*Token Level Eval* e *Sequence Similarity Eval*), ed un file `web_parsing.py` con al suo interno tutte le funzioni, una per ogni dominio assegnato, utili ad effettuare il parsing del testo estratto ed una funzione che permette di convertire il testo in Markdown.

All'interno di entrambe le cartelle ci sono i due file `Dockerfile` per permettere la creazione dei due container separati. La cartella principale del progetto include il file `docker-compose.yaml` per permettere, tramite il comando `docker compose up -build`, di far partire l'intero progetto. Include inoltre il file `domain.json` nel quale sono presenti i domini supportati.

È presente la cartella `gs_data` dove sono stati caricati i *gold standard*, ovvero per ogni dominio sono stati inseriti 5 indirizzi con `url`, `titolo`, `dominio`, `html_text` e `gold_text` per permettere di effettuare la valutazione.

3 Valutazione parser

La valutazione del parsing viene effettuata tramite due funzioni. Entrambe prendono in ingresso due testi:

- il testo restituito dal parsing
- il testo registrato dentro il `gold_standard`

Le due funzioni sono:

• Token Level Eval:

Divide i due testi in token (ovvero in parole) e confronta i due insiemi trovati dai due testi. La funzione restituisce un dizionario Python formato da:

- **precision** : confronta il numero di token trovati
- **recall** : quanti token effettivi sono stati trovati
- **F1** : media bilanciata tra precision e recall

• Sequence Similarity Eval:

Questa metrica valuta la struttura e l'ordine esatto del testo, calcolando :

- **similarity ratio** : indica quanto i due testi si somigliano complessivamente, penalizza refusi, spazi in più e parole inserite in ordine sbagliato
- **longest contiguous match** : il numero più lungo di caratteri continui identici al testo esatto
- **perfect match** : valore booleano che indica se il testo è completamente identico